



현대캐피탈 3차 세션 진행안

3차 세션은 전달주신 3가지 케이스를 기반으로, 외부 개발한 Agent를 Code Serving으로 배포·서빙하고 운영 단계까지 이어지는 전체 흐름을 확인하는 방향으로 준비하고자 합니다.

기존 예제 Agent를 활용하여 Git → 외부 연동 → 배포/서빙 → 운영 확인까지 하나의 케이스로 연결해 시연할 예정입니다.

1. 전체 구성

외부 환경

Frontend에서 GenOS Code Serving Endpoint 호출

GenOS 내부 환경

1. 외부에서 구성된 Agent 이관
2. Agent API를 Code Serving을 통해 배포
3. Code Serving Endpoint를 통한 외부 요청 처리
4. Agent에서 GenOS 내/외부 Resource(RAG,RDB) 활용

Text2SQL(외부DB), RAG(내부 VDB), HITL, Multi-turn 등의 Agent 기능 구성 및 시연

전체적인 요청 흐름은 아래와 같습니다.

사용자 → 외부 Frontend → Code Serving Endpoint → Agent → GenOS 내/외부 Resource(RAG) → Agent → Streaming Response → Frontend

2. 주요 확인 내용

① 코드서빙 기반 Agent 구성 및 배포

외부에서 Agent를 구성하고, Code Serving을 이용해 Agent API 형태로 배포하는 전체 과정을 확인합니다.

이를 통해 현대캐피탈에서 기존에 개발한 Agent를 GenOS 환경에서 서비스하기 위해 필요한 코드 구조, 환

경 설정 및 배포 방식을 함께 설명드릴 예정입니다.

② 외부 Frontend와 Code Serving 연동

외부에 배포된 Frontend에서 GenOS 내부 Code Serving Endpoint를 호출하여 Agent와 통신하는 구조를 구성합니다.

특히 실제 서비스 연동을 고려하여 요청 및 응답 구조를 Frontend에서 처리하는 과정을 확인할 예정입니다.

③ Session 기반 Multi-turn 구성

Frontend에서 Agent API를 호출할 때 Session ID와 같이 대화를 식별하기 위한 값을 Header 또는 요청 데이터에 전달할 수 있는지 확인하고, 해당 값을 Agent에서 활용하여 Multi-turn 구성 방안을 확인합니다.

이 과정에서 다음 내용을 중점적으로 확인할 예정입니다.

1. Code Serving 호출 시 Custom Header 전달 가능 여부
2. 동일 Session의 후속 요청에서 이전 대화를 이어가는 방식(Multi-turn)

④ Text2SQL / RAG / HITL 동작 확인

전달주신 케이스를 기준으로 다음 기능들을 함께 시연할 예정입니다.

- Text2SQL: 자연어 요청을 기반으로 내부 데이터 조회 및 결과 활용
- RAG(AI Drive): GenOS 내부 데이터/리소스를 검색하여 Agent 응답 생성 및 사용자의 보안에 따른 검색 필터링
- HITL: Agent 실행 과정에서 사용자 확인 또는 승인이 필요한 경우 실행을 제어하고 이후 프로세스를 이어가는 방식
- Multi-turn: 이전 대화 Context를 활용한 연속적인 질의응답

⑤ 로그 모니터링

외부 Frontend의 요청이 Code Serving을 통해 Agent로 전달된 이후, Agent의 내/외부 Resource 활용 내역을 추적하고 모니터링하는 방법을 확인할 예정입니다.

- 내부 Resource의 호출 및 GenOS 외부 통신에 대한 로그/Trace 확인

3. 3차 세션 목표

이번 세션을 통해 최종적으로

└외부 Agent 이관 → 외부 서비스 연동 → Code Serving 배포 → Session 기반 Multi-turn → Text2SQL/RAG/HITL 활용 → 운영 단계 모니터링┘

까지의 전체 흐름을 확인하고, 현대캐피탈에서 기존에 개발한 Agent를 GenOS 환경에서 실제 서비스 형태로 구성할 수 있도록 하는 것을 목표로 하고 있습니다.

위와 같은 방향으로 준비하고자 하며, 추가로 확인이 필요하거나 세션에서 함께 다루었으면 하는 내용이 있으시면 말씀 부탁드립니다.